# Google Play 数据处理智能体

设计、应用与实验

闫灿宇　周静雯　戴想然　赵思嘉

数据仓库与数据挖掘项目报告

**摘　要**

应用商店数据为竞品比较、产品定位和应用筛选提供了基础，但缺失评分、重复记录和混合单位等问题会直接影响分析结果。本文面向 Google Play 应用数据，设计并实现了集质量分析、策略规划、预处理、聚类和结果追溯于一体的数据处理智能体。系统以包含 10,841 条记录、13 个字段的历史数据为对象，由 DeepSeek 根据质量统计选择受约束的清洗策略，本地工具完成执行与校验。主实验设置最低必要处理、固定规则和智能体三组，分别保留 7,729、10,357 和 8,892 条聚类记录；在共同的 7,424 条完整记录上，固定簇数后分群结果一致。12 项记录复核及三次补充调用进一步检验了规则执行与决策稳定性。项目保留原始数据、逐条变更、完整模型请求与响应，支持无 API 调用的离线复算，为应用数据分析提供了一套可运行、可检查的处理流程。项目仓库：`https://github.com/zjw-buaa/Data-Mining-sol`。

**关键词：**数据质量；工作流智能体；Google Play；K-Means；可追溯处理

## 1　项目背景与目标

### 1.1　应用场景

应用和游戏开发者在产品立项、竞品研究及版本规划中，往往需要同时比较用户评分、评论规模、安装档位、包体大小和收费方式。把这些维度放在一起，可以识别规模相近的产品群，避免只按评分高低选取竞品，也可为包体控制、定价方式和目标用户定位提供分析线索。对应用筛选与推荐服务而言，分群结果能够帮助组织候选应用，再结合类别与使用需求缩小比较范围。

这些分析首先依赖可信的数据。原始商店记录中，大小可能以 M 或 k 表示，安装量带有逗号和加号，评分可能缺失，同一个名称也可能出现多次。如果直接计算距离或按名称去重，就可能把格式差异当作产品差异，或误删并不相同的采集记录。因此，本项目将数据质量处理放在分群之前，并把每一步处理的依据保留下来。

### 1.2　系统定位

系统采用一次规划、受约束执行的工作流：程序先识别质量问题，模型选择去重及缺失值处理策略，工具按确定规则执行，最后输出聚类画像与运行记录。用户不必逐条清洗数据，也不必反复编写相同的统计、转换和核验代码，而是把精力集中在策略检查和结果解释上。这种组织方式旨在降低重复劳动及沟通成本，并使处理经验能够复用。

项目的输出分为三部分：面向分析的清洗表和簇画像，面向复核的变更表和异常隔离表，以及面向复现的日志、运行清单和校验结果。正文先介绍数据、架构与使用方法，再集中说明技术实现和实验结果。

# 2 数据集与质量特征

## 2.1 数据来源和记录含义

项目使用 Kaggle 发布者 Lavanya（lava18）的 Google Play Store Apps 数据集，仅使用其中的应用列表表，未合并用户评论表。仓库文件为 `data/raw/googleplaystore.csv`，共 10,841 条记录、13 个字段，数据许可为 CC BY 3.0，来源与许可说明见 `data/README.md`。这是历史采集快照，2026 年 10 月 24 日为本项目获取日期，并非商店信息的采集日期。

一行表示一条应用采集记录。`App` 是展示名称，不能直接作为唯一实体标识；`Installs` 是商店公布的安装区间标记，解析后的数值表示档位下界。表 1 概括各字段在项目中的作用。

**表 1** 原始字段与使用方式

| 字段 | 含义 | 处理或用途 |
|---|---|---|
| App | 应用展示名称 | 保留原值，用于展示和追溯，不作为去重键 |
| Category | 商店类别 | 用于类别中位数计算和分群解释 |
| Rating | 用户评分 | 检查 0–5 范围，作为聚类特征 |
| Reviews | 评论数 | 转为非负整数，作为规模特征 |
| Size | 应用大小 | 统一为 MB，保留特殊状态标志 |
| Installs | 安装档位 | 去逗号和加号，提取档位下界 |
| Type | Free / Paid | 与价格联合检查一致性 |
| Price | 价格 | 解析美元数值，作为聚类特征 |
| Content Rating | 内容年龄分级 | 保留原值，辅助说明适用人群 |
| Genres | 流派或类型 | 保留文本，辅助解释产品类别 |
| Last Updated | 最近更新日期 | 统一日期格式，记录解析失败 |
| Current Ver | 当前版本 | 保留版本文本及缺失状态 |
| Android Ver | 系统版本要求 | 保留文本及特殊状态 |

## 2.2 质量检查结果

**表 2** 原始数据中的主要质量问题

| 类型 | 检查结果 | 处理关注点 |
|---|---|---|
| 缺失值 | 评分缺失 1,474 条 | 其中 878 条有评论，仍不能据此恢复评分 |
| 重复记录 | 完全重复的多余记录 483 条 | 按 13 个原始字段比较，不按应用名称合并 |
| 异常与错位 | 核心字段错位 1 条 | 同时出现非法评分、评论量、安装量和价格 |
| 混合单位 | 8,829 条 M；316 条 k | 统一 MB，`1k = 0.001 MB` |
| 特殊大小 | 1,695 条随设备变化 | `Varies with device` 不转为 0 或负数 |
| 其他缺失 | Type 1；分级 1；版本 8；系统版本 3 | 分别记录，不因非建模字段缺失整体删行 |

数据来源：`results/final/quality_before.json`。各项可能落在同一记录上，不相加解释为异常总数。

对高评论数、高安装档位或高价格记录，系统先检查格式和取值是否合法，而不是仅凭数值较大就删除。原始值始终保留，解析值、填补值及处理标志另列存储，使异常判断和后续建模能够分别检查。

# 3 系统设计与工作流

## 3.1 总体架构

系统由数据质量工具、模型规划器、策略校验器、聚类模块和证据输出模块组成。模型只读取质量统计及少量样例，返回结构化策略；数据转换和数值计算由本地 Python 程序承担。三组方案共用解析、隔离、特征变换及评价模块，差异限定在去重与缺失值策略。

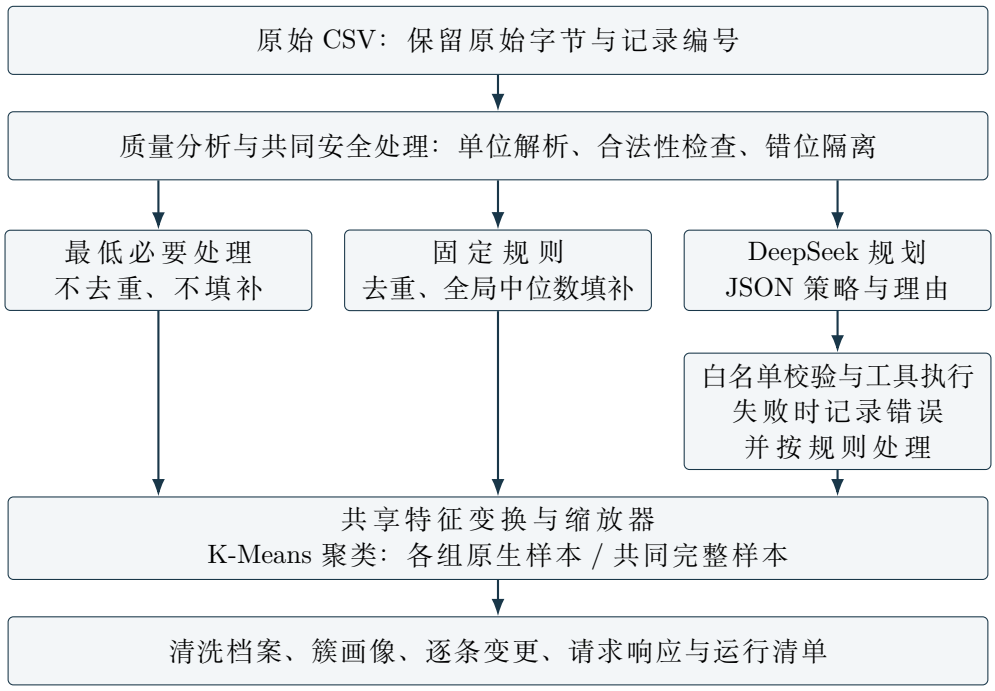



**图 1** 数据处理与聚类工作流

## 3.2 策略边界与模块职责

规划器的输出包含 `policy` 与 `reasons` 两部分。可选动作只有三个：是否删除完全重复记录、如何处理评分缺失、如何处理大小不可用。后两项仅可选 `drop`、`global_median`、`category_median`。其中 `drop` 表示记录仍保留在清洗档案中，只是不进入聚类；类别中位数要求同类别至少有 20 个有效观测，否则回退全局中位数。

| 仓库模块 | 职责 |
|---|---|
| `src/quality.py` | 质量统计、字段解析、隔离、去重、缺失处理与结果检查 |
| `src/agent.py` | 组装提示词、调用模型、验证计划并记录响应 |
| `src/clustering.py` | 特征变换、共享缩放、聚类及一致性评价 |
| `src/pipeline.py` | 编排三组流程，组织输出、日志和运行清单 |
| `src/plots.py` | 生成质量、处理过程和聚类结果图表 |
| `scripts/replay.py` | 根据已记录的真实策略离线重算并核对结果 |

模型不生成可直接执行的代码，也不根据聚类分数反复调整策略。执行器只接受通过校验的白名单动作，原始文件不被覆盖，三组结果分开保存。

# 4 安装、使用与结果阅读

## 4.1 首次运行

项目采用命令行入口 run.py。正式复现使用 Python 3.12 与 requirements.lock.txt 中的锁定依赖。以下命令在 Windows PowerShell 中执行；直接调用虚拟环境解释器，无需调整系统脚本策略。

```
git clone https://github.com/zjw-buaa/Data-Mining-sol.git
cd Data-Mining-sol
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.lock.txt
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
.\.venv\Scripts\python.exe run.py --replay
```

macOS 或 Linux 可在创建虚拟环境后执行 source .venv/bin/activate，再使用 python 运行相同命令。已有核验环境为 Windows、Python 3.12.14，其他平台以实际回放校验结果为准。

## 4.2 三种使用方式

**离线复现**。初次使用建议执行 run.py --replay。程序读取原始数据和保存的模型策略，重新完成预处理与聚类，不需要 API 密钥。成功时终端输出 status: verified、csvs: 26、jsons: 8 和 new_api_calls: 0。结果按时间戳写入新建的 results/replay/ 子目录，不会覆盖正式记录。

**运行本地基线**。执行 run.py --smoke --agent off 可用小样本检查环境；执行 run.py --agent off --no-figures 可运行完整两组基线。去掉 --no-figures 后生成图表。

**重新调用模型**。Windows 可执行 .\scripts\run_deepseek.ps1，按隐藏输入提示提供自己的 API 密钥。也可安全配置 LLM_BASE_URL、LLM_MODEL、LLM_API_KEY，再执行 run.py --agent required。保存实验使用的地址为 https://api.deepseek.com，模型标识为 deepseek-flash；重新调用使用个人额度，模型可用性以账号为准。

## 4.3 从输出定位一条记录

正式主实验位于 results/final/，其中 minimum/、fixed/、agent/ 分别对应三组。建议先看总览，再看簇画像，最后按记录编号检查处理过程。

**表 3** 结果阅读入口

| 相对路径（位于 results/final） | 可以回答的问题 |
|---|---|
| comparison.csv | 各组保留了多少记录，采取了多少次填补，分群指标如何 |
| agent/cluster_profiles.csv | 每个簇的规模、评分、大小和价格特征是什么 |
| agent/cleaned.csv | 某条记录的原值、解析值、填补标志和聚类资格是什么 |
| agent/changes.csv | 对这条记录做了什么，为什么这样处理 |
| agent/quarantine.csv | 哪些记录被隔离，具体触发了什么检查 |
| agent_status.json | 模型最终选择了什么策略，调用是否完成 |
| logs/pipeline.jsonl | 模型收到什么、返回什么，各工具执行了哪些动作 |

source_row_id 从 1 开始编号，不含 CSV 表头。若出现输入哈希或数值不一致，应先核对原始文件、核心源码和依赖版本，不修改校验值来跳过错误。完整命令与常见问题见 docs/REPRODUCE.md。

# 5 技术实现与实验分析

## 5.1 预处理与特征构造

程序读取原始字段后，新增记录编号及解析状态。大小转换为 MB；评论数转换为非负整数；安装量去除逗号和末尾加号；价格去除美元符号；日期统一为 ISO 格式。对无法解释为合法核心值的记录进行隔离，保留原值及原因。去重以全部 13 个原始字段相同为条件，只移除多余副本。

缺失处理区分观测值与建模值。`rating_observed`、`size_mb_observed` 保留原始可用观测，`rating_value`、`size_mb` 存放建模值，`*_imputed` 标记是否填补。`eligible_for_clustering` 和 `cluster_exclusion_reason` 记录聚类资格及排除原因。这样，即使使用中位数建模，也可以辨认哪些数值并非原始观测。

聚类使用评分、评论数、大小、安装档位下界和价格五个特征。设原始特征向量为 $x = (r, v, s, i, p)$，变换为

$$z = \big(r, \log(1+v), \log(1+s), \log(1+i), \log(1+p)\big).$$

对数变换用于缓和规模与价格的长尾分布，随后采用标准化 $\tilde{z}_j = (z_j - \mu_j)/\sigma_j$。缩放器在去重且五项特征均完整的 7,424 条参考记录上拟合，三组共用相同参数，避免各组量纲变化干扰比较。

## 5.2 为什么设置三组方案

三组分别回答不同的问题：最低必要处理给出“不填补、不额外去重时”的起点；固定规则体现常规自动清洗的结果；智能体组观察模型根据数据情况选择策略后，样本保留和分群如何变化。三个方案共同运行，才能把基础解析、固定策略与模型决策各自的作用放在同一框架下检查。

**表 4** 主实验中的三组处理策略

| 处理环节 | 最低必要处理 | 固定规则 | 智能体 |
|---|---|---|---|
| 单位解析与错位隔离 | 相同 | 相同 | 相同 |
| 完全重复的多余记录 | 保留 | 移除 | 移除 |
| 评分缺失 | 排除聚类 | 全局中位数 | 排除聚类 |
| 大小不可用 | 排除聚类 | 全局中位数 | 类别中位数 |
| 策略来源 | 最小处理基线 | 预先写定 | 一次真实模型决策 |

## 5.3 聚类与评价设置

各组使用自身可参与聚类的记录，在 $k = 2, 3, 4, 5, 6$ 中按抽样轮廓系数选择簇数。K-Means 固定 `seed=42`、`n_init=10`、`max_iter=300`、`tol=1e-4`，并限制单线程。轮廓系数最多抽取 1,500 条记录计算，另保存 Davies–Bouldin（DB）和 Calinski–Harabasz（CH）指标。

对样本 $i$，轮廓系数为 $s(i) = [b(i) - a(i)]/\max\{a(i), b(i)\}$，其中 $a(i)$ 为簇内平均距离，$b(i)$ 为距最近其他簇的平均距离；越大通常表示分群越清晰。由于三组原生样本不同，这里的跨组分数用于描述各自结果，不直接作为策略优劣排名。另设共同完整样本比较，固定 7,424 条记录和 $k = 4$，单独检查同一输入上的分群一致性。

### 5.4 主实验结果与应用解释

主实验于 2026 年 10 月 26 日运行。三组均隔离 1 条核心字段错位记录；固定规则与智能体组分别移除 483 条完全重复的多余记录。清洗档案数与聚类记录数分开统计，前者保留可追溯资料，后者要求五项建模特征均可用。

**表 5** 主实验结果

| 指标 | 最低必要处理 | 固定规则 | 智能体 |
|---|---|---|---|
| 清洗档案数 | 10,840 | 10,357 | 10,357 |
| 参与聚类记录数 | 7,729 | 10,357 | 8,892 |
| 聚类保留率 | 71.29% | 95.54% | 82.02% |
| 评分填补次数 | 0 | 1,465 | 0 |
| 大小填补次数 | 0 | 1,526 | 1,526 |
| 选定簇数 $k$ | 3 | 3 | 3 |
| 抽样轮廓系数 | 0.3483 | 0.4178 | 0.3665 |
| DB 指数 | 1.0846 | 0.9991 | 1.0687 |

来源：`results/final/comparison.csv`。保留率分母均为原始 10,841 条；轮廓系数抽样量均为 1,500。填补次数按全部清洗档案统计。

固定规则组对评分与大小都进行填补，因此可用记录最多。智能体保留真实评分、不填补评分，但对不可用大小采用类别中位数，最终有 8,892 条记录进入聚类，比最低必要处理净多 1,163 条。这个净变化同时包含去重和大小填补的影响。智能体组共完成 1,526 次大小填补，本次没有触发全局中位数回退。

**共同样本说明了什么**。在 7,424 条共同完整记录上，三组变换后的特征最大差为 0，固定 $k = 4$ 后两两调整兰德指数（Adjusted Rand Index，ARI）均为 1。ARI 比较两套分组对“哪些记录属于同一组”的判断，并扣除随机一致的影响，可概括为

$$\mathrm{ARI} = \frac{\text{实际一致程度} - \text{随机期望一致程度}}{\text{最大一致程度} - \text{随机期望一致程度}}.$$

ARI 为 1 表示分组完全一致，接近 0 表示与随机一致程度相近，负值表示低于随机期望；簇标签的编号不同不影响它。本实验的 ARI 为 1 说明三套方案对这些未发生特征改变的共同记录给出了相同分群，主要差别出现在额外保留、移除或填补的记录上。

**表 6** 智能体组的簇画像（各特征为簇内中位数）

| 描述性分组 | 记录数 | 评分 | 评论数 | 大小/MB | 价格/美元 |
|---|---|---|---|---|---|
| 较大规模免费记录 | 4,712 | 4.3 | 60,695.5 | 18.0 | 0 |
| 较小规模免费记录 | 3,693 | 4.2 | 122 | 7.8 | 0 |
| 付费记录 | 487 | 4.4 | 291 | 11.0 | 3.99 |

三个簇的安装档位下界中位数分别为 500 万、1 万和 5 千。开发者可以据此先按规模和收费方式寻找比较对象，再结合类别筛选更接近的应用；面向用户的应用筛选也可沿用这种分层方式。画像中的名称是对统计特征的概括，不代表产品质量等级。数据见 `results/final/agent/cluster_profiles.csv`。

### 5.5 模型请求、提示词与响应

主实验调用 deepseek-flash 一次，请求与返回的模型标识一致。请求启用 JSON 对象输出，设置 thinking.type=disabled、max_tokens=4096，未显式设置温度或模型生成随机种子。输入为质量统计及 4 条缺失/特殊大小样例（编号 24、38、43、53），不发送整张数据表。

**系统提示词原文：**

```
你是 Google Play 数据质量处理计划智能体。只读质量统计和少量原始样例。
共同安全处理已固定：严格解析单位，隔离错位/非法核心值，不按数值大删除合法记录，
不凭 App 名称合并，不把特殊大小状态当-1 或 0，不推断评分缺失原因。
drop 策略表示保留 cleaned 档案但排除该记录参与聚类；只有 deduplicate 移除完全重复多余记录。
只能返回一个 JSON 对象：{"policy":{"deduplicate":true 或 false,
"rating":"drop/global_median/category_median 之一",
"size":"drop/global_median/category_median 之一"},
"reasons":{"deduplicate":" 具体理由","rating":" 具体理由","size":" 具体理由"}}。
category_median 工具要求同分类至少 20 个有效观测，否则回退全局中位数。
目标是合理、可追溯的数据处理，不能声称聚类分数必然提高。不输出代码或 markdown。
```

**用户消息结构及关键统计摘录：**

```
{"quality": {
  "row_count": 10841, "column_count": 13,
  "exact_duplicate_extra": 483,
  "missing_rating_positive_reviews": 878,
  "size_states": {"observed": 9145, "varies": 1695, "invalid": 1}
}, "examples": [原始样例记录 24、38、43、53]}
```

上段仅展示输入结构和部分统计；原始用户消息还包含各字段缺失数、错位记录及四条样例的完整字段，均保存在日志的 llm_request.body.messages 中。

**真实响应中的策略对象：**

```
{"deduplicate":true,"rating":"drop","size":"category_median"}
```

响应同时给出了三项理由：完全重复的多余记录可以移除，但不按名称合并；评分缺失时避免构造未观测的评分信号；大小特殊状态不当作 0 或负值，在类别样本足够时使用类别中位数作为建模代理。完整响应见 results/final/agent_status.json，原始响应 ID 为 3fec716d-b506-42df-ac54-9c73c20b2e60。

主实验输入 1,180 tokens，输出 232 tokens，合计 1,412 tokens，记录耗时约 2.12 秒。加上三次补充实验，共 4 次真实调用、5,489 tokens。运行时未配置有效单价，cost_usd=null，实际账单费用未记录。请求、响应及用量均可在 results/final/logs/pipeline.jsonl 和补充运行目录中核对。

### 5.6 工具调用、记录变更与错误处理

**主实验执行轨迹**。表 7 摘录智能体分支的实际日志，时间为 2026 年 10 月 26 日北京时间。模型先给出计划，随后工具执行该计划；解析、去重、缺失处理和结果验证分别记录，可以逐项核对计划与实际动作。

**表 7** 智能体分支的运行记录摘录

| 时间 | 事件或工具 | 结果 |
|---|---|---|
| 22:57:13.298 | `llm_request` | 第 1 次请求，发送统计、样例和约束 |
| 22:57:15.418 | `llm_response` / `agent_status` | 收到响应并通过计划校验 |
| 22:57:16.927 | `parse_and_quarantine` | 10,841 条中隔离 1 条，余 10,840 条 |
| 22:57:16.953 | `exact_deduplicate` | 移除 483 条完全重复的多余记录 |
| 22:57:16.955 | `missing_strategy`：评分 | 1,465 条缺失评分记录排除聚类 |
| 22:57:17.014 | `missing_strategy`：大小 | 填补 1,526 条，回退次数为 0 |
| 22:57:17.056 | `verification` | 清洗档案 10,357 条，聚类记录 8,892 条 |
| 随后 | 聚类候选、共同样本及图表事件 | 写出指标、画像、图表与运行清单 |

**行级变更**。记录编号贯穿原始数据、清洗档案和变更日志。以下案例体现了“格式修正、异常隔离、重复移除、缺失策略”四类动作的区别。

**表 8** 典型记录的处理去向

| 记录编号 | 原始情况 | 智能体组的处理结果 |
|---|---|---|
| 59 | 大小为 `201k` | 解析为 0.201 MB，保留单位转换依据 |
| 10473 | 评分 19，安装量为 Free，多列错位 | 进入隔离表，记录各项非法原因 |
| 230 | 与编号 223 的 13 个原始字段相同 | 移除多余副本，保留去重记录 |
| 24 | 评分缺失，评论数为 61 | 保留清洗档案，不进入聚类 |
| 38 | 大小为 `Varies with device` | 保留特殊状态，以类别中位数 8.95 MB 建模 |
| 4368 | 价格为 400 美元 | 数值合法，保留，不按高价格直接删除 |

**错误与修正机制**。若响应不是合法 JSON、字段不完整或策略超出白名单，程序记录 `llm_validation_error`，追加“上一次响应未通过本地校验：{error}。请按约定重新返回 JSON。”，再请求一次。两次均不通过时以 `invalid_plan` 结束，不执行该计划。连接或超时错误记为 `llm_transport_error` 和 `api_error`，不会用固定规则伪装为模型结果。

已保存的主实验和三次补充调用均一次通过结构校验，没有发生 API 失败或校验重试，因此没有对应的实际纠错往返。

### 5.7 人工复核、稳定性与离线复现

**人工复核**。从缺失、重复、异常、格式四类问题中各选 3 条，共 12 条原始记录，逐条检查三组共 36 个处理结果。复核关注处理是否符合规则、原始信息是否保留、去留和建模值是否能由日志解释。12 条均填写“合理”，未记录需要修改的处理结果。

**表 9** 12 项记录复核的覆盖范围

| 问题类型 | 记录编号 | 复核重点 |
|---|---|---|
| 缺失 | 24、114、479 | 原始缺失、填补标志与聚类资格是否对应 |
| 重复 | 230、237、240 | 是否仅移除完全重复的多余副本 |
| 异常 | 10473、2809、4368 | 错位隔离与合法极值保留是否有依据 |
| 格式 | 59、1、38 | 单位、安装档位与大小特殊状态是否解释正确 |

结构化结果见 `docs/review/records.csv`，逐条依据见 `docs/review/details.docx`。这一步的作用是检查程序是否把预定策略落实到具体记录，并为数量统计补充可阅读的案例依据。

**三次真实调用的稳定性**。2026 年 10 月 27 日，使用相同原始数据、核心程序、可观察请求参数和依赖，新增三次真实模型调用。仓库沿用原始编号 02、03、04，对应补充第 1、2、3 次。每次均独立保存请求、响应、策略和运行结果。

**表 10** 补充实验中的策略及分群变化

| 编号 | 去重 | 评分 | 大小 | 聚类数 | $k$ | 轮廓系数 |
|---|---|---|---|---|---|---|
| 02 | 是 | drop | drop | 7,424 | 4 | 0.3441 |
| 03 | 是 | drop | drop | 7,424 | 4 | 0.3441 |
| 04 | 是 | drop | category_median | 8,892 | 3 | 0.3665 |

三次调用对去重与评分策略的选择一致，大小策略出现两种选择。这项补充实验把“同一计划能否重现”与“模型是否每次给出同一计划”区分开：前者由离线回放检查，后者由重复真实调用观察。补充实验样本量为 3，不将首次主实验并入其均值和标准差；详细统计见 `results/stability/runs.csv` 与 `results/stability/metrics_summary.csv`。

**离线复现与证据组织**。回放从原始 CSV 和日志中已记录的策略重新计算，先检查数据及核心源码哈希，再核对 26 个 CSV、8 个 JSON，耗时字段除外。程序在回放期间阻止网络连接。主实验及补充 02、03、04 均已有成功回放记录，新 API 调用数均为 0；补充实验的大表通过指纹核验后重新生成，不必重复保存多套相同结构的大文件。

```
python run.py --replay --recorded-run results/stability/runs/02
python run.py --replay --recorded-run results/stability/runs/03
python run.py --replay --recorded-run results/stability/runs/04
```

`run_manifest.json` 固定输入、核心源码和依赖版本；`result_fingerprints.json` 保存补充实验结果指纹；`pipeline.jsonl` 串联请求、响应、工具与核验事件。三者共同构成从输入到结果的复现依据。

# 6 总结

本项目围绕 Google Play 应用数据，完成了从质量检查、策略规划到聚类分析的完整流程。受约束的模型规划把需要判断的策略选择与可重复执行的程序规则分开；逐条变更、隔离表和观测/填补标志则使每一项处理都有据可查。用户既可以直接阅读簇画像，也可以沿记录编号返回原始数据与执行日志。

三组对照展示了不同预处理策略对样本覆盖的影响：最低必要处理提供起点，固定规则保留更多可建模记录，智能体则选择去重、保留真实评分并按类别处理大小。共同样本上的一致分群说明，对照中的主要变化来自样本组成与代理值，而不是同一完整输入上的算法差异。记录复核、重复真实调用和离线回放分别补充了规则合理性、决策一致性和计算可复现性三个方面的证据。

在应用层面，这套流程能够把重复的数据检查、转换和结果整理交给工具完成，为开发者与分析人员腾出精力进行竞品筛选和业务解释。后续迁移到新的商店快照或其他业务数据时，需要先调整字段约定、质量规则和输入校验，再沿用策略规划、工具执行与证据保存的组织方式。

## 6.1 局限与后续改进

当前结果来自历史快照；12 项复核覆盖选定案例，三次补充调用也仅反映有限的决策变化。大小策略及个别文字理由仍有波动，现有实验尚不能证明填补准确性或聚类效果的优势，也未量化人力与费用节省。后续可通过观测值遮蔽实验评估填补误差，增加独立调用，并加入理由与策略的语义一致性检查。

## 6.2 小组分工

项目围绕整体统筹、数据与文档、实验分析、质量复核四个方向开展分工，具体职责见表 11。

**表 11** 小组职责分工

| 成员 | 负责范围 |
| --- | --- |
| 闫灿宇 | 项目整体把控、进度推进与汇报展示 |
| 周静雯 | 数据集调研、GitHub 仓库整理、实验报告撰写与汇报 PPT 制作 |
| 戴想然 | 实验方案设计、技术实现与结果分析 |
| 赵思嘉 | 数据质量与预处理策略研究、人工复核及结果解释 |